

解釈可能な深層 VAR モデルの提案

局所解釈性と効果的なスパース制約

栗田 煌矢

June 9, 2026

多変量時系列データから知見 (依存関係や因果関係) を得る方法は様々である。

おおざっぱに、既存モデルの特徴を挙げる。

- 線形モデル：複雑な非線形関係は捉えられない。検定や解釈が可能 (例：VAR, VAR-LiNGAM)
- 非線形モデル：複雑な非線形関係を捉えうる。検定や解釈 (例えば影響の正負) が不可能 (例：DBN, Transfer Entropy)
- 両者共通：分析に使うラグを決める必要がある。

これらの短所をうまく具合に解決する、複雑でないモデルを作りたい。

提案手法について

本手法は、多変量時系列データに対して解釈性を保ちながら深層学習手法を適用し、Granger 因果構造 (変数間の影響構造) を推定する。

主な特徴は次の 3 点である。

- GVAR(Generalized Vector Autoregression) により、状態依存的かつ符号解釈が可能な自己回帰係数を学習する。
- Neural Granger Causality 型の正則化により、回帰係数を適切にスパース化する。
- 学習可能な `causal_gate` に近接勾配法を適用し、厳密なゼロを生成する。

背景：GVAR と Neural Granger Causality

提案手法は、次の2つの既存手法を参考に行っている。

- GVAR：状態依存的な係数行列をニューラルネットワークで生成する (Marcinkevičs, R., & Vogt, J. E., 2021)。
- Neural-GC：ニューラルネットワークに構造的スパース性を導入し、Granger 因果性を推定する (Tank et al., 2021)。

中心的な拡張は、

$$\text{causal_gate.shape} = [\text{lag}, \text{target}, \text{source}]$$

という学習可能なゲートを導入した点である。

p 変量時系列を

$$x_t = (x_{t,1}, \dots, x_{t,p})^\top \in \mathbb{R}^p$$

とする。自己回帰次数を K とすると、一般化 VAR(GVAR) は次のように表される。

$$x_t = \sum_{k=1}^K \Phi_k(x_{t-k}) x_{t-k} + \varepsilon_t$$

ここで、 $\varepsilon_t \in \mathbb{R}^p$ は誤差項であり、 $\Phi_k(x_{t-k}) \in \mathbb{R}^{p \times p}$ はラグ k に対応する状態依存的な係数行列である。各成分で書くと、

$$x_{t,i} = \sum_{k=1}^K \sum_{j=1}^p \Phi_{k,i,j}(x_{t-k}) x_{t-k,j} + \varepsilon_{t,i}$$

$\Phi_{k,i,j}(x_{t-k})$ はラグ k における変数 j から変数 i への局所的な影響を表す。

Causal Gate による構造制御 (提案 1)

本手法では、各ラグの係数行列 $\Phi_k(x_{t-k})$ に対して静的な causal gate を掛ける。

$$G_k \in \mathbb{R}^{p \times p}$$

有効係数行列は次で定義される。

$$\tilde{\Phi}_k(x_{t-k}) = G_k \odot \Phi_k(x_{t-k})$$

ここで $\odot$ は Hadamard 積である。動的な係数変動は Φ_k が表現し、構造的な因果の有無を G_k が制御する。

影響の「構造」は一定、影響の「度合い」は入力値依存という仮定を置いている。

Granger 非因果性の定義 (Tank et al., 2021)

変数 x_j が変数 x_i を Granger cause しないための十分条件は、すべてのラグにおいて x_j から x_i への効果がゼロであることである。つまり、

$$G_{1,i,j} = G_{2,i,j} = \dots = G_{K,i,j} = 0$$

causal gate の値が全てのラグにおいて 0 であれば、最終的な係数行列 $\tilde{\Phi}_k(x_{t-k})$ は、どんな入力値であろうと 0 になる。

$\Phi_k(x_{t-k})$ は入力値依存なので、同じラグでも 0 になる場合とならない場合が考えられる。そのため、非因果性は causal gate で定義した。

予測は、ラグごとの有効係数行列を用いて定義される。

$$\hat{x}_t = \sum_{k=1}^K \tilde{\Phi}_k(x_{t-k})x_{t-k}$$

係数は入力依存のため、その形状は

[batch, lag, target, source]

であり、causal gate は入力依存でないため、

[lag, target, source]

の形を持つ。

Temporal Smoothness(≡局所線形性)

GVAR は時点ごとに状態依存係数を生成するため、係数が過度に振動しないように平滑化ペナルティを導入する。

absolute mode では次のペナルティを用いる。

$$\mathcal{R}_{\text{smooth}} = \frac{1}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \left\| \tilde{\Phi}_{t+1} - \tilde{\Phi}_t \right\|_F^2$$

これにより、同じ変数でもラグをまたいで大きく係数の値 (符号) が変わるという不自然な動きを抑制し、過学習防止や解釈の妥当性を実現する

目的関数

学習目的関数は、予測損失、時間方向の平滑化、NGC 正則化からなる。

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \lambda_{\text{smooth}} \mathcal{R}_{\text{smooth}} + \lambda_{\text{ngc}} \mathcal{R}_{\text{ngc}}$$

予測損失は平均二乗誤差である。

$$\mathcal{L}_{\text{pred}} = \frac{1}{N} \sum_t \|x_t - \hat{x}_t\|_2^2$$

Sparse Group Lasso(Tank et al.,2021)

本手法では NGC の sparse group lasso を causal gate に適用する。
各 target-source pair (i,j) について、ラグ方向の gate vector を

$$g_{i,j} = (G_{1,i,j}, \dots, G_{K,i,j})$$

と定義する。

正則化項は次である。

$$\mathcal{R}_{\text{ngc}} = w_{\text{group}} \sum_{i,j} \|g_{i,j}\|_2 + w_{\text{l1}} \sum_{k,i,j} |G_{k,i,j}|$$

group 項は edge 全体の削除、L1 項は lag 単位の削除に対応する。

Iterative Shrinkage-Thresholding Algorithm(ISTA)

提案手法では、近接勾配法 (ISTA) と呼ばれる閾値処理アルゴリズムにより、正則化で限りなく 0 に近づいた要素を厳密な 0 に更新する。
まず smooth part のみに対して勾配ステップを行う。

$$\mathcal{L}_{\text{smooth-part}} = \mathcal{L}_{\text{pred}} + \lambda_{\text{smooth}} \mathcal{R}_{\text{smooth}}$$

その後、causal gate に対して近接作用素を適用する。

$$G^{(m+1)} = \text{prox}_{\eta\lambda_{\text{ngc}} \mathcal{R}_{\text{ngc}}} \left(G^{(m+1/2)} \right)$$

これにより、causal gate に厳密なゼロが生じる。

近接更新の2段階

sparse group lasso の近接更新は2段階で行われる。

まず、elementwise soft-thresholding により lag 単位の厳密なスパース性を作る。

$$G_{k,i,j} \leftarrow \text{sign}(G_{k,i,j}) (|G_{k,i,j}| - \eta \lambda_{\text{ngc}} w_{l1})_+$$

次に、各 edge (i,j) の lag vector に対して group soft-thresholding を行う。

$$g_{i,j} \leftarrow \left(1 - \frac{\eta \lambda_{\text{ngc}} w_{\text{group}}}{\|g_{i,j}\|_2}\right)_+ g_{i,j}$$

SGD・Adam と近接勾配法 (ISTA) の違い

XNeural VAR では、adam と ista の 2 種類の optimizer を選択できる。

- SGD・Adam

- 目的関数全体を通常の勾配降下法ベースで最適化する。
- 実装は簡単だが、目的の要素 (ここでは causal gate) が厳密なゼ 0 になりにくい。

- ista

- 通常の勾配法を行った後、gate に近接作用素を適用する。
- 厳密な 0 を作るため、Granger 構造推定に適している。

学習後、モデルは全データに対して有効係数テンソルを計算する。
係数ベースの causal strength は、係数の絶対値を batch 方向および lag 方向に集約して得る。

$$S_{i,j} = \max_{t,k} \left| \tilde{\Phi}_{k,i,j}(x_{t-k}) \right|$$

ただし、最終的な causal graph は coefficient thresholding ではなく、gate norm に基づいて推定する。

$$\hat{A}_{i,j} = \mathbf{1} [\|g_{i,j}\|_2 > \tau]$$

提案手法のパッケージ化

(<https://github.com/koyarctan/Xneural-VAR>)

XNeural VAR は、機能ごとにモジュール化されている。

- `xneural_var.models`
GVAR/SENN モデルと causal gate を実装する。
- `xneural_var.regularizers`
sparse group lasso、hierarchical group lasso、近接作用素を実装する。
- `xneural_var.training`
学習ループ、ログ出力、結果オブジェクトを扱う。

本手法の要点は次の通りである。

- GVAR により、非線形かつ状態依存的な自己回帰ダイナミクスを表現する。
- causal gate により、動的係数と静的な Granger 構造を分離する。
- sparse group lasso により、edge 全体と lag 単位の両方をスパース化する。
- ISTA により、causal gate に厳密なゼロを生成する。
- 平滑化制約によって自然な状態依存係数の推移を実現。解釈の妥当性を生む。