

解釈可能な深層 VAR の提案

東北大学経済学部 4 年 李研
栗田 煌矢

July 19, 2026

VAR(ベクトル自己回帰) モデルは、複数の時系列データの相互依存関係を表現するためのモデルである。

$$x_t = \sum_{k=1}^K \Phi_k x_{t-k} + \varepsilon_t$$

x_t は時点 t の多変量ベクトル、 Φ_k はラグ k に対応する係数行列。
本研究は VAR に代表される多変量時系列解析がテーマとなる。

提案手法について

- ① GVAR により、状態依存的かつ符号解釈が可能な係数行列を学習する。
- ② Neural Granger Causality 型の正則化により、係数行列を効果的にスパース化する。
- ③ 学習可能な `causal_gate` に近接勾配法を適用し、係数行列の厳密なゼロと、自動ラグ選択を実現。

提案手法について

次を同時に満たす点が特徴であり、貢献であると考える。

- ① 非線形・状態依存性：時点ごとに変化する効果を表現できる。
- ② 構造スパース性：存在しない変数間関係を厳密なゼロとして除去できる。
- ③ 係数としての解釈性：ラグ、符号、効果の大きさを読み取れる。

手法	非線形・状態依存	厳密な構造スパース性	係数の解釈
VAR	×	○	○
LSTM	○	×	×
NGC	○	○	×
GVAR	○	×	○
本研究	○	○	○

非線形のわりにはリッチな解釈をシンプルに行えるモデルを目指した。


背景：GVAR と Neural Granger Causality

提案手法は、次の2つの既存手法を causal gate で統合している。

- ① GVAR：状態依存的で符号解釈が可能な係数行列をニューラルネットワークで生成する (Marcinkevičs, R., & Vogt, J. E., 2021)。
- ② Neural-GC：ニューラルネットワークに構造的スパース性を導入し、Granger 因果性を推定する (Tank et al., 2021)。

`causal_gate.shape = [lag, target, source]`

提案手法の全体像



$$\tilde{\Phi}_{k,t} = G_k \odot \Phi_{k(x_{t-k})}, \quad \hat{x}_t = \sum_{k=1}^K \tilde{\Phi}_{k,t} x_{t-k}$$

p 変量時系列を

$$x_t = (x_{t,1}, \dots, x_{t,p})^\top \in \mathbb{R}^p$$

とする。自己回帰次数を K とすると、一般化 VAR(GVAR) は次のように表される。

$$x_t = \sum_{k=1}^K \Phi_{k(x_{t-k})} x_{t-k} + \varepsilon_t$$

$\Phi_{k(x_{t-k})} \in \mathbb{R}^{p \times p}$ はラグ k に対応する**状態依存的**な係数行列であり、これがニューラルネットの出力となる。

特徴：係数の符号解釈が可能であるが、事後的な閾値処理が必要。

Neural Granger Causality (NGC) (Tank et al.,2021)

NN のスパース制約を工夫し、Granger 因果性を推定する手法である。

Theorem (Tank et al.,2021)

変数 j が変数 i を Granger cause しないための十分条件は、すべてのラグにおいて j から i への重みがゼロであることである。

この条件を満たすように、入力層重みに対して構造的な厳密スパース最適化 (近接勾配法) を行う。

特徴：事後的な閾値処理はいらないが、係数の符号は意味を持たない。

ラグごとの係数行列それぞれに対して causal gate を適用。最終的な係数行列は次で定義される。

$$\tilde{\Phi}_{k(x_{t-k})} = G_k \odot \Phi_{k(x_{t-k})} \quad , \quad G_k \in \mathbb{R}^{p \times p}$$

動的な係数変動は $\Phi_{k(x_{t-k})}$ が表現し、全体としての Granger 因果の有無を G_k が制御するという役割の分離。

本研究ではこの gate に構造スパース制約をかけることで Granger 因果性を推定する。

係数 $\Phi_{k(x_{t-k})}$ は入力値依存であるため、同じラグの入力なのに値によって係数が 0 になる場合とならない場合がある。

入力に依存しない `causal_gate` を設け、構造スパース化をかけることで

$$G_{1,i,j} = \cdots = G_{K,i,j} = 0$$

なら、任意の入力に対して $j \rightarrow i$ の有効係数は 0。

入力値依存性に惑わされず、gate のみで因果性を解釈できる。

本研究の Granger 非因果性の定義

変数 x_j が変数 x_i を Granger cause しないための十分条件は、すべてのラグにおいて x_j から x_i への効果がゼロであることである。つまり、

$$G_{1,i,j} = G_{2,i,j} = \cdots = G_{K,i,j} = 0$$

causal gate の値が全てのラグにおいて 0 であれば、最終的な係数行列 $\tilde{\Phi}_k(x_{t-k})$ は、どんな入力値であろうと 0 になる。
したがって、非因果性を主張するためには、gate の値を厳密な 0 にする工夫が必要である。

予測損失、時間方向の平滑化、NGC 正則化からなる。

$$\mathcal{L} = \mathcal{L}_{\text{pred}} + \mathcal{R}_{\text{smooth}} + \mathcal{R}_{\text{ngc}}$$

予測損失は平均二乗誤差である。

$$\mathcal{L}_{\text{pred}} = \frac{1}{N} \sum_t \|x_t - \hat{x}_t\|_2^2$$


状態依存係数を用いるため、係数が過度に振動しないための平滑化ペナルティ；

$$\mathcal{R}_{\text{smooth}} = \frac{\lambda_{\text{smooth}}}{|\mathcal{T}|} \sum_{t \in \mathcal{T}} \left\| \tilde{\Phi}_{t+1} - \tilde{\Phi}_t \right\|_F^2$$

同じ変数でもラグをまたいで大きく係数の値 (or 符号) が変わるという不自然な動きを抑制し、過学習防止や解釈の妥当性を実現する。

NGC 型正則化 : Sparse Group Lasso

Sparse Group Lasso は、特定の変数のエッジをすべてのラグでまとめて 0 にする圧力と、特定のラグの特定の変数のエッジを 0 にする圧力の両方を与える。




$$\mathcal{R}_{\text{SGL}}(G) = \lambda_{\text{group}} \sum_{i,j} \|G_{:,i,j}\|_2 + \lambda_{\text{sparse}} \sum_{k,i,j} |G_{k,i,j}|$$

第 1 項は edge 単位の削除、第 2 項は lag 単位の削除を促す。

NGC 型正則化：Hierarchical Group Lasso

Hierarchical Group Lasso は古いラグに対応する gate の要素を優先的にゼロにする圧力をかけ、ラグの自動選択を実現する。



$$\mathcal{G}_{k,i,j} = (G_{k,i,j}, \dots, G_{K,i,j}), \quad \mathcal{R}_{\text{HGL}}(G) = \lambda_{\text{ngc}} \sum_{i,j} \sum_{k=1}^K \|\mathcal{G}_{k,i,j}\|_2$$

Optimizer ; 近接勾配法 (ISTA)

ISTA は正則化で 0 に近づいたパラメータを、厳密に 0 にするための手法である。ISTA では次の 2 段階で `causal_gate` を更新する。

- ① 予測損失と平滑化項に通常の勾配更新
- ② 更新後の gate を近接更新

$$\text{勾配更新} \longrightarrow \text{近接更新} \longrightarrow G_{k,i,j} = 0$$

ここで使う超パラメータは、

$$\eta\lambda$$

であり、モデルのパラメータ自体を 0 にする収縮圧力の強さをあらわす。

事後的な閾値処理との違い


比較

- 近接勾配法で係数値が厳密に 0 になった変数は、モデル学習での推論過程に使われていない。
- 事後的な閾値処理では、学習中に小さい非ゼロ値の変数が推論過程に使われる。

事後的な閾値処理で Granger 非因果性を主張しても、モデル学習には微小に使われてしまっていることになるため近接勾配法などで学習中に厳密に 0 にすることが望ましい。

学習後の解釈

- 1 causal gate からの Granger 因果行列 $\hat{A}$
- 2 有効係数 $\tilde{\Phi}_{k,t}$



$$g_{i,j} = (G_{1,i,j}, G_{2,i,j}, G_{3,i,j}), \quad \hat{A}_{i,j} = \mathbf{1} [\|g_{i,j}\|_2 > \tau]$$

- $\hat{A}_{i,j} = 0$ なら、変数 j の過去が変数 i の予測に寄与しないと判定する。
- 有効係数 $\phi_{k,t}$ の符号を見れば、目的変数への効果の方向を解釈できる。

次の3点を、検証する。

- ① 閾値を置かずに Granger 因果グラフを得られるか
- ② 真の Granger 因果構造をどのとらえるか
- ③ 状態依存係数の符号は真の方向と一致するか

データ	系列長・次元	生成の設定	モデル共通の設定
線形 VAR	$T = 500, p = 10$		$K = 5$
Lorenz-96	$T = 500, 1000 \quad p = 20$	$F = 40$	$K = 5$

- 比較手法：GVAR、NGC(cMLP)、linear VAR。
- neural model は全データ・full batch、150 epoch。校正 seed と評価 seed を分離。
- cMLP と提案手法は各 λ の厳密ゼロを評価。

Lorenz-96 は、気象モデル由来のカオス的な非線形力学系である。局所相互作用が既知のため、非線形 Granger 因果推定の標準的な合成ベンチマークとして用いられる。


$$\frac{dx_i}{dt} = (x_{i+1} - x_{i-2})x_{i-1} - x_i + F$$

$$A_{i,j} = 1 \iff j \in \{i, i+1, i-1, i-2\}.$$


- NGC 論文： $p = 20$, $F \in \{10, 40\}$, $T \in \{250, 500, 1000\}$ で評価。
- 本実験：NGC 著者コードに合わせ、 $T = 500$, $\Delta t = 0.05$, burn-in 1000, 観測ノイズ $\mathcal{N}(0, 0.1^2)$ を使用。
- 真の非自己 edge は $j \in \{i+1, i-1, i-2\}$ の 60 本。

線形データ：設計と比較結果

線形データ：causal gate




線形データ：有効係数の符号確認



Lorenz-96($F=40, T=1000$) : 比較結果

Lorenz-96($F=40, T=500$) : 比較結果

Lorenz-96($F=40, T=500$) : λ_{ngc} によるスコア推移



まとめ

本手法の要点は次の通りである。

- GVAR の状態依存係数に、NGC 型の構造正則化を causal gate として導入した。
- causal gate により、動的な有効係数と静的な Granger 因果構造を分離した。

これらの工夫により実現したのは、

- 近接勾配法による構造 gate の厳密なスパース化
- lag-wise causal gate によるラグ構造の可視化
- 有効係数分布による係数符号の確認

実験において、

- Lorenz-96 ($F = 10, 40$) では、Xneural VAR が GVAR を全構造指標で上回った。
- 一方、構造推定精度は NGC(cMLP) が最も高く、提案手法は及ばなかった。
- 線形 VAR では、厳密ゼロのグラフ ($F1=0.629$) と符号一致率 0.750 を同一モデルで得た。
- したがって、最高精度よりも「状態依存係数の符号解釈」と「閾値不要の構造」の両立が本手法の強みである。

本手法の課題は次の通りである。

- causal gate は因果構造の変化を捉えない。
- causal gate の識別性 (今は非負制約を課していない)
- λ_{ngc} 付近で edge 数が急変するため、安定なチューニングが必要。
- 実データへの適用可能性